

Índice

1	Introducción	3
1.1	Contexto y Relevancia del problema	3
1.2	Preguntas de investigación	4
1.3	Objetivos	4
1.4	Contribución del Estudio	5
1.5	Estructura del documento	6
2	Revisión Literaria	7
2.1	Hechos estilizados de la volatilidad financiera	7
2.2	Modelos simétricos: ARCH y GARCH	9
2.3	Modelos asimétricos: EGARCH, GJR-GARCH y APARCH	9
2.4	Evaluación estadística: <i>in-sample</i> y <i>out-of-sample</i>	10
2.5	Esquemas de estimación: ventana fija y ventana móvil	11
2.6	De la precisión estadística al valor económico	13
2.7	Evidencia empírica del DJIA y brecha identificada	14
3	Metodología	15
3.1	Datos y construcción de la serie de retornos	15
3.2	Justificación estadística del uso de GARCH	16
3.3	Especificación de los modelos de volatilidad	17
3.3.1	ARCH (1)	18
3.3.2	GARCH (1,1)	19
3.3.3	EGARCH (1,1)	20
3.3.4	GJR-GARCH (1,1,1)	21
3.3.5	APARCH (1,1,1)	22
3.4	Esquemas de estimación	23
3.4.1	<i>Fixed Window</i>	23
3.4.2	<i>Rolling Window</i>	24
3.5	Generación y evaluación de pronósticos de volatilidad	24
3.6	Aplicación financiera mediante valuación de opciones	25
3.6.1	Modelo Black-Scholes	26
3.6.2	Conversión de pronósticos GARCH a volatilidad anualizada	27
3.6.3	Benchmark de volatilidad histórica	27
3.6.4	Dataset de Opciones	28
3.7	Métricas de error en <i>pricing</i>	28
3.8	Implementación y reproducibilidad	30
4	Resultados	30
4.1	Evidencia empírica inicial de la serie de retornos	30
4.2	Resultados <i>in-sample</i> bajo esquema <i>Fixed Window</i>	34
4.3	Pronóstico <i>out-of-sample</i> de Varianza	35

4.4	Aplicación Económica: Pricing de Opciones	37
5	Conclusión	41
6	Bibliografía	43
7	Apéndices	45
7.1	Apéndice A: Errores en Pronósticos de Varianza Realizada	45
7.2	Apéndice B: Dispersión Relativa de Varianza Pronosticada frente Varianza Realizada	49

1. Introducción

1.1. Contexto y Relevancia del problema

La volatilidad es una de las variables centrales en los mercados financieros porque resume la incertidumbre asociada al comportamiento futuro de los precios y funciona como un insumo crítico para la gestión de riesgo, la valuación de derivados, la asignación de portafolios y la toma de decisiones de inversión. En contextos de estabilidad, una estimación razonable de la volatilidad permite dimensionar pérdidas potenciales, definir coberturas y valorar instrumentos financieros con mayor precisión. En periodos de estrés como crisis financieras, episodios de alta inflación, shocks geopolíticos o eventos extraordinarios como la pandemia de COVID-19, su relevancia aumenta de forma significativa porque pequeños errores de medición pueden amplificarse en pérdidas económicas relevantes, requerimientos de capital mal calibrados o decisiones estratégicas subóptimas.

El problema adquiere mayor importancia porque la volatilidad no es directamente observable. A diferencia del precio de un activo, que puede observarse en el mercado, la volatilidad debe estimarse a partir de información histórica, precios de derivados o modelos estadísticos. Esta característica introduce un reto metodológico donde distintos modelos pueden generar estimaciones distintas para el mismo activo incluso cuando utilizan la misma información de mercado. Por ello, la elección del modelo de volatilidad no es una decisión puramente técnica, sino una decisión con implicaciones económicas directas.

En el caso de la valuación de opciones, la precisión en la estimación de volatilidad es especialmente relevante. En el modelo Black-Scholes, la volatilidad es el único insumo no observable y tiene un efecto directo sobre el precio teórico del derivado. Una subestimación puede producir precios artificialmente bajos y generar primas insuficientes frente al riesgo asumido. Una sobreestimación puede encarecer las opciones y limitar operaciones potencialmente rentables. En ambos escenarios, el resultado es una asignación ineficiente de recursos y una pérdida de precisión en la medición del valor económico del instrumento.

La literatura financiera ha documentado que los retornos de los activos presentan hechos estilizados incompatibles con una volatilidad constante. Entre estos destacan la presencia de colas pesadas, leptocurtosis, clustering de volatilidad, persistencia, reversión a la media y respuestas asimétricas ante choques positivos y negativos. Estos patrones justifican el uso de modelos de volatilidad condicional, particularmente la familia ARCH/GARCH y sus extensiones, porque permiten que la varianza esperada dependa de información pasada y se ajuste dinámicamente a las condiciones del mercado.

Sin embargo, no existe un consenso absoluto sobre cuál especificación GARCH es superior en todos los contextos. Un modelo puede mostrar buen ajuste dentro de muestra y perder capacidad predictiva fuera de muestra. Otro puede pronosticar adecuadamente la varianza realizada y no generar los mejores precios de opciones. Esta distinción es fundamental porque el objetivo final de un modelo financiero no siempre es minimizar una métrica estadística, sino

mejorar una decisión económica concreta. Bajo esta lógica, evaluar modelos de volatilidad únicamente por su ajuste estadístico puede ser insuficiente cuando el uso final es la valuación de derivados.

Este estudio se sitúa precisamente en esa intersección entre precisión estadística y utilidad económica. Al analizar el Dow Jones Industrial Average durante el periodo 2000-2025, el proyecto evalúa si distintos modelos de la familia GARCH no solo capturan la dinámica de la volatilidad del mercado, sino también si sus pronósticos aportan valor tangible al incorporarse en el *pricing* de opciones. De esta forma, el problema de investigación no se limita a identificar qué modelo predice mejor la volatilidad, sino a determinar si esa mejora se traduce en precios de opciones más cercanos a los observados en el mercado.

1.2. Preguntas de investigación

En respuesta a los vacíos identificados, este trabajo formula dos preguntas de investigación principales: 1. ¿Cuál modelo de la familia GARCH, entre ARCH, GARCH, EGARCH, GJR-GARCH y APARCH, ofrece el mejor desempeño predictivo para la volatilidad del DJIA durante el periodo 2000-2025, considerando tanto criterios de ajuste *in-sample* como métricas de precisión *out-of-sample* bajo diferentes esquemas de estimación? 2. ¿En qué medida las mejoras estadísticas, en el pronóstico de la volatilidad, generan valor económico real medido a través de la precisión en *pricing* de opciones financieras?

1.3. Objetivos

El primer objetivo general responde a la dimensión estadística, mientras que el segundo objetivo general corresponde a la dimensión económica. Cada uno se desglosa en tres objetivos específicos que establecen una progresión lógica desde la estimación hacia la evaluación y de lo estadístico hacia lo económico.

1. Objetivo General 1: Comparar el desempeño predictivo de distintos modelos de la familia GARCH en la estimación y pronóstico de la volatilidad condicional del Dow Jones Industrial Average, evaluando su robustez estadística y estabilidad bajo diferentes condiciones de mercado.
 - Objetivo Específico 1: Implementar y estimar diferentes especificaciones de la familia GARCH utilizando datos diarios de retornos.
 - Objetivo Específico 2: Evaluar el desempeño *out-of-sample* de los modelos mediante métricas de pérdida apropiadas para pronósticos de volatilidad y pruebas formales de comparación de modelos.
 - Objetivo Específico 3: Analizar la estabilidad y consistencia del desempeño predictivo de los modelos a nivel individual y agregado bajo distintos regímenes de mercado.

2. Objetivo General 2: Determinar si el uso de volatilidad pronosticada mediante modelos GARCH genera valor económico medible en aplicaciones financieras de *pricing* de opciones.
- Objetivo Específico 1: Incorporar la volatilidad pronosticada en esquemas de evaluación Black-Scholes para generar precios teóricos de opciones.
 - Objetivo Específico 2: Comparar los errores de valuación frente a alternativas basadas en volatilidad histórica e implícita.

1.4. Contribución del Estudio

La principal contribución de este estudio consiste en integrar, dentro de un mismo marco empírico, la evaluación estadística de modelos de volatilidad y su aplicación económica en la valuación de opciones financieras. En lugar de limitar la comparación a criterios tradicionales de ajuste o a métricas de pronóstico de varianza, el trabajo conecta los modelos GARCH con una aplicación concreta de mercado que corresponde al cálculo de precios teóricos de opciones mediante Black-Scholes utilizando volatilidad pronosticada como insumo. Esto permite evaluar si las mejoras estadísticas realmente generan valor económico medible.

El estudio también contribuye al comparar de forma sistemática cinco especificaciones de la familia GARCH. Las especificaciones analizadas son ARCH(1), GARCH(1,1), EGARCH(1,1), GJR-GARCH(1,1,1) y APARCH(1,1,1). Esta selección permite contrastar modelos simétricos y asimétricos junto con especificaciones con distintos niveles de flexibilidad paramétrica. La inclusión de EGARCH, GJR-GARCH y APARCH permite analizar si capturar efectos de apalancamiento, asimetría y colas pesadas mejora la predicción de volatilidad y el desempeño en *pricing* frente a modelos más simples.

Otra contribución relevante es la comparación entre dos esquemas de estimación que corresponden a ventana fija y ventana móvil. Esta dimensión es importante porque la muestra 2000-2025 incluye episodios de cambio estructural y alta volatilidad como la crisis dot-com, la crisis financiera global, la pandemia de COVID-19 y el periodo posterior de ajuste. Al contrastar ambos esquemas, el estudio evalúa si resulta más conveniente preservar una base histórica amplia o actualizar los parámetros con mayor sensibilidad a la información reciente. Así, la elección de ventana deja de ser un detalle operativo y se convierte en una dimensión central del análisis.

El proyecto aporta además evidencia empírica específica para el Dow Jones Industrial Average, un índice de referencia con características distintas a otros benchmarks ampliamente estudiados. La base de retornos diarios permite construir pronósticos de varianza acumulada a 21 días, horizonte que posteriormente se alinea con la muestra de opciones sobre DJX. Esta consistencia temporal fortalece el vínculo entre la evaluación estadística de volatilidad y la aplicación económica en opciones con vencimiento comparable.

En términos de resultados, el estudio muestra que la selección del “mejor” modelo depende del objetivo de evaluación. APARCH presenta el mejor ajuste *in-sample* bajo AIC y BIC. EGARCH

con ventana fija obtiene el mejor desempeño *out-of-sample* frente a varianza realizada bajo QLIKE. GJR-GARCH con ventana móvil genera el menor error de *pricing* en las categorías de *money* analizadas. Esta evidencia contribuye al debate metodológico porque demuestra que precisión estadística y utilidad económica no son equivalentes y que el modelo óptimo debe seleccionarse en función del uso final.

Finalmente, el estudio documenta que incorporar volatilidad condicional dinámica mejora el *pricing* frente al *benchmark* tradicional de volatilidad histórica de 252 días. La reducción del error es particularmente relevante en opciones *at-the-money* y *near-the-money*, donde la sensibilidad del precio a la volatilidad es mayor. Con ello, el trabajo aporta evidencia de que los modelos GARCH no solo capturan regularidades estadísticas de los retornos, sino que también pueden mejorar decisiones financieras concretas cuando se aplican de forma alineada con el horizonte y objetivo económico del instrumento.

1.5. Estructura del documento

El documento se organiza en siete secciones. La primera sección presenta la introducción del estudio, donde se expone el contexto y la relevancia del problema, se plantean las preguntas de investigación, se definen los objetivos generales y específicos, se establece la contribución del trabajo y se describe la estructura general del documento.

La segunda sección desarrolla la revisión literaria. En ella se abordan los principales hechos estilizados de la volatilidad financiera. Entre ellos se incluyen colas pesadas, clustering, persistencia, reversión a la media y asimetría. Posteriormente se revisan los modelos simétricos ARCH y GARCH junto con las extensiones asimétricas EGARCH, GJR-GARCH y APARCH. También se discuten los criterios de evaluación *in-sample* y *out-of-sample*, los esquemas de estimación mediante ventana fija y ventana móvil, la relación entre precisión estadística y valor económico y la brecha empírica que justifica la aplicación al DJIA.

La tercera sección presenta la metodología. Primero se describe la construcción de la base de datos de retornos diarios del Dow Jones Industrial Average y el cálculo de la varianza realizada a 21 días. Después se justifica estadísticamente el uso de modelos GARCH mediante pruebas de estacionariedad, autocorrelación y dependencia en segundos momentos. Posteriormente se especifican los modelos de volatilidad utilizados, los esquemas de estimación, la generación de pronósticos de varianza acumulada y la métrica QLIKE para evaluación estadística. Finalmente, se detalla la aplicación financiera mediante Black-Scholes, la conversión de pronósticos GARCH a volatilidad anualizada, el *benchmark* de volatilidad histórica, la base de opciones DJX y las métricas de error en *pricing*.

La cuarta sección reporta los resultados empíricos. En primer lugar, se presenta la evidencia descriptiva inicial de los retornos del DJIA incluyendo estadísticos, distribución empírica, pruebas de diagnóstico y evidencia visual de clustering de volatilidad. Después se muestran los resultados *in-sample* bajo criterios AIC y BIC seguidos por la evaluación *out-of-sample* de pronósticos de varianza mediante QLIKE. La sección cierra con la aplicación económica al

pricing de opciones, donde se comparan los errores de valuación por categoría de *moneyness* y se evalúa el desempeño de los modelos frente al *benchmark* de volatilidad histórica.

La quinta sección presenta las conclusiones del estudio. En esta parte se sintetizan los principales hallazgos, se discute la diferencia entre desempeño estadístico y desempeño económico, se interpreta la superioridad de GJR-GARCH con ventana móvil en *pricing* de opciones y se señalan las limitaciones del trabajo. También se proponen líneas futuras de investigación que incluyen la extensión del análisis a otros activos, otros mercados, distintos vencimientos, métricas de cobertura y modelos de *pricing* que incorporen directamente dinámicas GARCH bajo una medida neutral al riesgo.

La sexta sección contiene la bibliografía utilizada, incluyendo las referencias fundamentales sobre modelos ARCH/GARCH, hechos estilizados de volatilidad, evaluación de pronósticos, selección de ventanas, modelos de *pricing* de opciones y aplicaciones empíricas relacionadas. Finalmente, la séptima sección incluye los apéndices, donde se presentan gráficos complementarios de errores en los pronósticos de varianza realizada y diagnósticos de dispersión relativa entre varianza pronosticada y varianza realizada para cada modelo y esquema de estimación.

2. Revisión Literaria

2.1. Hechos estilizados de la volatilidad financiera

La justificación empírica para modelar dinámicamente la volatilidad financiera surge de una regularidad principal, siendo esta que aunque los rendimientos de los activos suelen mostrar baja dependencia lineal, su variabilidad no se comporta como ruido blanco. La evidencia de Mandelbrot et al. (1963) y Fama (1965) cuestiona directamente el supuesto gaussiano clásico al documentar que las variaciones de precios presentan distribuciones con gran concentración en el centro y colas más pesadas que las implicadas por la normalidad.

Mandelbrot et al. (1963) plantea que los precios de mercado exhiben desviaciones extremas con una frecuencia mayor a la esperada bajo un proceso browniano tradicional, proponiendo distribuciones estables paretianas como alternativa para capturar dicha evidencia empírica. Fama (1965), por su parte, reconoce que las distribuciones de cambios en precios presentan leptocurtosis, es decir, demasiadas observaciones alrededor de la media y demasiadas observaciones en las colas, lo que hace insuficiente el supuesto de normalidad como descripción estadística de los retornos financieros.

Un segundo hecho estilizado, posterior a la evidencia de colas pesadas y leptocurtosis es el *volatility clustering*. La evidencia reportada por Mandelbrot et al. (1963) y Fama (1965) muestra que los movimientos grandes tienden a ser seguidos por movimientos grandes, y los movimientos pequeños por movimientos pequeños, aún cuando el signo de dichos movimientos sea difícil de predecir. Esta regularidad implica que el nivel de riesgo observado hoy afecta la expectativa de riesgo futuro. Engle & Patton (2001) formalizan esta intuición al señalar que un buen modelo

de volatilidad debe capturar persistencia, reversión a la media y asimetría, ya que la función práctica de estos modelos no es únicamente describir la varianza histórica, sino pronosticar la volatilidad relevante para la gestión de riesgo, valuación de derivados, cobertura, asignación de portafolios y *market making*.

Cont (2001) consolida estos hallazgos en una taxonomía de hechos estilizados observables en distintos mercados, activos y frecuencias. Entre los más relevantes para la modelación dinámica de la volatilidad destacan *heavy tails*, *volatility clustering*, *conditional heavy tails*, *slow decay of autocorrelation in absolute returns* y el *leverage effect*. La principal aportación de Cont no es únicamente identificar estas propiedades sino, mostrar que son suficientemente robustas como para considerarse regularidades empíricas que cualquier modelo de volatilidad debe tomar en cuenta.

La literatura ARCH/GARCH surge como una respuesta a esta necesidad de modelar una varianza condicional dinámica. Bollerslev et al. (1992) señalan que, aunque el *volatility clustering* ya era una regularidad empírica conocida en precios especulativos de alta frecuencia, la modelación explícita de la varianza condicional se volvió central con el desarrollo de los modelos ARCH y sus extensiones. Estos modelos permiten que la varianza esperada dependa de la información pasada, capturando la idea de que los choques recientes afectan el riesgo futuro.

Además de persistente, la volatilidad financiera exhibe reversión a la media. Engle & Patton (2001) argumentan que el *volatility clustering* implica que la volatilidad aparece en episodios, pero dichos episodios no son permanentes, los periodos de alta volatilidad eventualmente ceden hacia niveles más normales, y periodos de baja volatilidad tienden a revertir hacia niveles superiores. Esta propiedad es relevante para el diseño de modelos, ya que un buen modelo debe permitir que los choques tengan efectos duraderos más no infinitos sobre la varianza esperada.

Finalmente, la evidencia empírica muestra que la respuesta de la volatilidad no es simétrica. Christie (1982) documenta una relación negativa entre el valor del equity y la volatilidad de los retornos accionarios. Esto se explica por el apalancamiento financiero, cuando cae el precio de la acción, aumenta el ratio deuda-capital y con ello la volatilidad del rendimiento para los accionistas. Este mecanismo es la base del *leverage effect*, que explica cómo choques negativos elevan la volatilidad futura más que los choques positivos de magnitud equivalente. Engle & Patton (2001) refuerzan este punto al señalar que, para retornos accionarios es poco realista asumir que innovaciones positivas y negativas tengan el mismo impacto sobre la volatilidad y que este fenómeno se ve reflejado en las distribuciones de precios pronosticados y la forma de la superficie de volatilidad implícita de opciones.

En conjunto, estos hechos estilizados constituyen el fundamento empírico para modelar la volatilidad de forma dinámica. Las colas pesadas y la leptocurtosis invalidan la normalidad como supuesto base; el *volatility clustering* revela dependencia temporal en la varianza; la persistencia y la reversión a la media exigen modelos capaces de transmitir choques al futuro sin hacerlos permanentes y el *leverage effect* obliga a distinguir entre el signo y la magnitud de las innovaciones.

2.2. Modelos simétricos: ARCH y GARCH

Bajo este marco, la pregunta ya no es si la volatilidad es dinámica, sino cómo parametrizar esa dinámica de forma consistente con la evidencia empírica. Para ello, Engle (1982) introduce el modelo *Autoregressive Conditional Heteroskedasticity* (ARCH), cuya premisa central es que la varianza condicional en el período t depende de los cuadrados de los errores pasados, reproduciendo el *clustering* de volatilidad documentado por Mandelbrot et al. (1963) y Fama (1965). Sin embargo, suele presentar problemas de parsimonia en muestras finitas ya que para capturar la persistencia de la volatilidad observada se requiere un número elevado de rezagos. Bollerslev (1986) aborda este problema al proponer el *Generalized ARCH* (GARCH), que incorpora rezagos de la propia varianza condicional, logrando capturar esa misma persistencia con tan solo tres parámetros que captan el nivel, la reacción a los choques y la persistencia: ω (omega), α (alpha) y β (beta).

La solidez empírica del GARCH(1,1) como especificación de referencia está respaldada por la literatura de los últimos años, P. R. Hansen & Lunde (2005) comparan 330 modelos de la familia ARCH en su *survey*, y concluyen que es notablemente difícil de superar cuando el criterio de evaluación es estadístico. Por ello, se incluye como *benchmark* natural en la comparación de este estudio.

No obstante, tanto el ARCH como el GARCH comparten una limitación estructural fundamental: su especificación es simétrica. En ambos modelos, el impacto de un choque sobre la varianza condicional depende únicamente de su magnitud y no de su dirección, de modo que, un choque negativo y uno positivo de igual magnitud generan exactamente el mismo incremento en la volatilidad condicional. Esta limitante es insostenible en los mercados de renta variable; ya que como Christie (1982) documenta, los choques negativos generan incrementos de volatilidad sistemáticamente mayores que los positivos de igual magnitud.

2.3. Modelos asimétricos: EGARCH, GJR-GARCH y APARCH

Superar la limitante de simetría exige modelos que distingan entre el signo y la magnitud de los choques, y la literatura ofrece tres respuestas estructuralmente distintas.

Nelson (1991) propone el modelo *Exponential GARCH* (EGARCH) con dos innovaciones estructurales. Primero, modelar el logaritmo de la varianza condicional en lugar de la varianza directamente, eliminando la necesidad de imponer restricciones de no negatividad sobre los parámetros. Segundo, incorporar tanto la magnitud como el signo de los choques pasados en la ecuación de la varianza condicional, permitiendo que choques negativos y positivos de igual tamaño tengan efectos diferenciados sobre la volatilidad futura.

Glosten et al. (1993) proponen una alternativa más parsimoniosa, la cual es que el modelo GJR-GARCH extiende la especificación del GARCH estándar incorporando una variable indicadora que activa un término adicional en la ecuación de la varianza condicional únicamente cuando el choque del período anterior es negativo. Engle & Ng (1993) demuestran que el GJR-GARCH

captura mejor la respuesta asimétrica de la volatilidad ante noticias negativas frente a noticias positivas, lo que explica su amplia adopción en la literatura empírica.

La especificación más flexible de las tres es el modelo *Asymmetric Power ARCH* (APARCH), introducido por Ding et al. (1993). El modelo APARCH generaliza simultáneamente el tratamiento de la asimetría y la potencia sobre la cual se mide la varianza condicional ya que, en lugar de modelar la varianza condicional directamente, modela una potencia flexible δ de la desviación estándar condicional, donde δ es un parámetro adicional estimado a partir de los datos. Fernández & Steel (1998) complementan esta especificación al formalizar la distribución *Skewed Student-t* utilizada en la estimación del modelo APARCH, demostrando que es necesario capturar asimetría en la distribución de los errores además de la asimetría en la ecuación de varianza. Por su parte, B. E. Hansen (1994) desarrolla un marco más general de estimación de densidades condicionales que permite que los parámetros de forma de la distribución varíen en función de la información disponible en cada período. Su propuesta de una distribución *Student-t* sesgada con parámetros dinámicos ofrece una alternativa que captura simultáneamente la no normalidad y la asimetría temporal de los errores, siendo metodológicamente compatible con las especificaciones APARCH estimadas en dicho estudio.

Posteriormente, Christoffersen et al. (2006) validan la relevancia de este enfoque al demostrar que capturar asimetría distribucional mejora el *pricing* de opciones más allá de lo que captura el efecto leverage en la ecuación de varianza, conectando directamente las propiedades del APARCH con el objetivo económico de esta investigación.

2.4. Evaluación estadística: *in-sample* y *out-of-sample*

Determinar cuál de estos modelos produce los pronósticos más precisos exige separar el ajuste sobre los datos de estimación y la capacidad predictiva sobre datos no vistos. En su revisión de más de noventa y tres estudios sobre pronóstico de volatilidad, Poon & Granger (2003) documentan que la superioridad de un modelo en ajuste *in-sample* no constituye evidencia suficiente de su superioridad predictiva fuera de muestra. Este resultado tiene la consecuencia metodológica de que un modelo más complejo como el APARCH puede superar al GARCH(1,1) en criterios AIC y BIC sobre los datos de entrenamiento y, no obstante, generar pronósticos *out-of-sample* inferiores debido a sobreajuste.

La evaluación *in-sample* se realiza a través de criterios de información que penalizan la complejidad del modelo. Akaike (1974) introduce el AIC, que balancea ajuste y parsimonia penalizando por el número de parámetros estimados. Por otro lado, Schwarz (1978) propone el BIC con una penalización más severa, siendo más conservador en la selección de modelos complejos. Ambos criterios son complementarios puesto que el AIC favorece modelos con mayor poder predictivo, mientras el BIC favorece la parsimonia.

Patton (2011) demuestra que dado que la volatilidad no es observable y debe ser calculada mediante un proxy con error de medición, la elección de la métrica de evaluación *out-of-sample* debe ser una función de pérdida que preserve el ranking entre modelos independientemente del

proxy utilizado, ya que éstas producen rankings estadísticamente válidos. QLIKE satisface este criterio, mientras que el RMSE no lo satisface. Por ello, el QLIKE se adopta como métrica de evaluación estadística en este estudio.

Sin embargo, es importante distinguir que la limitación del RMSE identificada por Patton (2011) aplica exclusivamente en la evaluación estadística *out-of-sample* con proxy imperfecto de volatilidad. Bajo este contexto, P. R. Hansen & Lunde (2005) corroboran que el uso de métricas como el RMSE puede producir rankings inconsistentes entre modelos de volatilidad no observable.

Por otra parte, la evaluación de modelos GARCH en el contexto de *pricing* de opciones no debe limitarse al desempeño estadístico de la predicción de volatilidad. Christoffersen & Jacobs (2004) muestran que los modelos favorecidos por criterios basados en retornos o *likelihood* no necesariamente son los que mejor funcionan cuando se evalúan en *pricing* de opciones, es decir, un modelo puede minimizar el error de predicción de volatilidad y, aun así, no minimizar el error de *pricing*. Esta conclusión es relevante para esta investigación ya que comparar modelos GARCH sólo con métricas estadísticas de volatilidad captura una dimensión incompleta del problema. Para resolver esto, y considerando que el precio de mercado es directamente observable, el uso de métricas de error como el RMSE y MAE son válidas y apropiadas para comparar el desempeño de los modelos en esta dimensión específica.

2.5. Esquemas de estimación: ventana fija y ventana móvil

La evaluación *out-of-sample* no solo exige determinar qué especificación produce el menor error de pronóstico, sino también bajo qué esquema se actualizan los parámetros que generan esos pronósticos.

Stock & Watson (1996) proveen la justificación empírica para no asumir estabilidad paramétrica de manera automática. En su análisis de 76 series macroeconómicas y 5,700 relaciones bivariadas, documentan que la inestabilidad estructural aparece en una fracción significativa de las relaciones estimadas y comparan modelos con distintos grados de adaptabilidad, desde especificaciones de parámetros *fixed* hasta *rolling regressions* y modelos con parámetros cambiantes. Aunque su aplicación es macroeconómica, la implicación metodológica es directamente relevante para el pronóstico de volatilidad puesto que si la relación estimada cambia en el tiempo, la forma en que un modelo conserva o actualiza información histórica puede alterar su desempeño fuera de muestra.

La ventana fija representa el esquema que privilegia estabilidad paramétrica. Bajo este enfoque, el modelo conserva una base histórica amplia para estimar sus parámetros, lo que puede reducir la variabilidad de las estimaciones y evitar que movimientos recientes, potencialmente transitorios, dominen la dinámica del modelo. Sin embargo, Stock & Watson (1996) muestran que los modelos de parámetros fijos pueden ser vulnerables cuando las relaciones presentan inestabilidad, ya que el supuesto de continuidad histórica puede dejar de ser válido en presencia

de cambios estructurales. En ese contexto, una ventana fija puede conservar observaciones que ya no representan adecuadamente el régimen vigente de la serie.

No obstante, Pesaran & Timmermann (2007) advierten que descartar información previa al quiebre tampoco es necesariamente óptimo. Su aportación central consiste en demostrar que, aun cuando existe un cambio estructural, puede ser conveniente utilizar datos anteriores al quiebre para estimar modelos de pronóstico. El argumento es que la información pasada puede introducir sesgo si los parámetros cambiaron, pero también puede reducir la varianza del error de pronóstico al ampliar la muestra de estimación. Por ello, la selección de ventana debe entenderse como un *trade-off* entre sesgo y varianza, donde una muestra demasiado amplia puede incorporar información de regímenes obsoletos, mientras que una muestra demasiado corta puede generar estimaciones más ruidosas.

La ventana móvil surge como una alternativa frente a esa tensión. Inoue et al. (2017) señalan que, ante evidencia de inestabilidad paramétrica, es común estimar los modelos utilizando únicamente observaciones recientes mediante *rolling estimation*. Bajo este esquema, el modelo se re-estima conforme avanza el tiempo, incorporando nueva información y excluyendo observaciones antiguas. Sin embargo, los autores también muestran que el desempeño predictivo puede ser sensible al tamaño de la ventana, por lo que el problema no consiste únicamente en elegir entre *fixed* y *rolling*, sino en reconocer que la cantidad de información utilizada puede alterar el ranking de los modelos fuera de muestra.

Esta discusión adquiere mayor relevancia en modelos GARCH porque la persistencia estimada de la volatilidad puede confundirse con cambios de régimen. Marcucci et al. (2005) señala que una preocupación recurrente en estos modelos es la persistencia excesiva de los choques, la cual puede producir pronósticos demasiado suaves o elevados entre periodos con distintos niveles de turbulencia. Además, retoma la evidencia de que cambios en la varianza incondicional pueden distorsionar los parámetros GARCH, haciendo que el modelo interprete como persistencia lo que en realidad proviene de quiebres estructurales. Bajo esta lógica, una muestra larga puede mezclar periodos de baja y alta volatilidad dentro de una misma estimación, mientras que una ventana móvil puede responder con mayor rapidez a cambios recientes en la dinámica de la serie.

En el horizonte 2000-2025, la comparación entre ambos esquemas resulta especialmente pertinente por la presencia de episodios como la crisis *dot-com*, la crisis financiera global de 2008, el COVID-19 y el periodo de ajuste posterior a la pandemia. Estos eventos pudieron modificar no solo el nivel de volatilidad, sino también su persistencia y su respuesta ante choques extremos. Por ello, comparar *fixed window* y *rolling window* permite evaluar si los pronósticos de volatilidad se benefician más de parámetros estimados con una base histórica amplia o de parámetros actualizados con mayor sensibilidad a cambios recientes. Debido a lo anterior, la comparación entre ambos esquemas forma parte de la contribución del estudio y no únicamente de su implementación metodológica.

2.6. De la precisión estadística al valor económico

La conexión entre los modelos de volatilidad condicional y la valuación de opciones surge directamente de una limitación del modelo de Black-Scholes, siendo esta que la volatilidad entra como un parámetro que se asume constante durante la vida de la opción. En el planteamiento original de Black & Scholes (1973), el precio del subyacente sigue un proceso continuo con varianza proporcional al cuadrado del precio, lo que implica que la tasa de varianza del rendimiento del activo se mantiene constante. Esta hipótesis permite derivar una fórmula cerrada bajo condiciones ideales de mercado, pero también impone una simplificación sobre el comportamiento real de los retornos.

Hull & White (1987) muestran que, cuando la volatilidad es estocástica e independiente del precio del activo, el precio correcto de la opción puede interpretarse como el valor esperado del precio Black-Scholes integrado sobre la distribución de la varianza promedio durante la vida del contrato. Además, analizan procedimientos numéricos y simulaciones Monte Carlo para aproximar el valor de la opción cuando no existe una solución simple. Su resultado también matiza los sesgos de Black-Scholes, esto es que el modelo tiende a sobrevaluar opciones *at-the-money* y a subvaluar opciones suficientemente *deep in-the-money* o *deep out-of-the-money*, con efectos que dependen del tiempo al vencimiento. Aunque Hull & White no estiman modelos GARCH, su contribución respalda la idea de que la volatilidad relevante para una opción debe vincularse al comportamiento esperado de la varianza durante la vida del contrato.

Complementariamente, Brooks & Persaud (2003) formalizan la construcción de pronósticos de volatilidad para horizontes de varios días, su propuesta consiste en generar pronósticos de varianza condicional para cada periodo futuro y agregarlos mediante la suma de dichas varianzas, ya que la varianza es aditiva en el tiempo. Este resultado es relevante para la valuación de opciones porque el parámetro de volatilidad no debe representar únicamente el riesgo del siguiente día, sino la incertidumbre esperada durante el horizonte completo del contrato. Por ello, el uso de varianza acumulada permite construir un *input* de volatilidad consistente con el vencimiento de la opción y evita extrapolar mecánicamente un pronóstico de un día hacia horizontes más largos.

Desde esta perspectiva, la incorporación de volatilidad pronosticada mediante modelos GARCH puede interpretarse como una adaptación empírica del marco Black-Scholes. Esta adaptación metodológica se presenta en dos enfoques distintos, el enfoque *plug-in* y los modelos formales de *option pricing* bajo GARCH. En lugar de asumir una volatilidad constante o utilizar una estimación histórica fija, el enfoque *plug-in* sustituye ese parámetro por una predicción de varianza condicional generada por un modelo GARCH. En los modelos formales, en cambio, la dinámica de la varianza forma parte del modelo de valuación bajo una medida de *pricing* o medida neutral al riesgo, como ocurre en Duan (1995), quien formaliza el *pricing* de opciones cuando los retornos del subyacente siguen un proceso GARCH mediante la *locally risk-neutral valuation relationship*. Esta medida permite valorar el derivado descontando sus pagos esperados a la tasa libre de riesgo. El presente estudio se ubica en el primer enfoque, donde se estiman modelos de la familia GARCH con datos históricos de retornos, se generan predicciones de

varianza y dichas predicciones se usan como insumo para calcular precios de opciones mediante Black-Scholes.

Esta lógica es consistente con Bi et al. (2014), quienes proponen utilizar GARCH(1,1) para obtener una medida de volatilidad que posteriormente se introduce en el modelo Black-Scholes. Su contribución es útil porque muestra una implementación parsimoniosa del acoplamiento GARCH-BS. No obstante, su alcance es limitado frente a los objetivos de este estudio. Al apoyarse en una medida de volatilidad de largo plazo, el enfoque sacrifica información sobre la estructura temporal específica del vencimiento de la opción. Además, se restringe a una sola especificación GARCH(1,1), por lo que no permite evaluar si modelos con asimetría o efectos de apalancamiento generan mejores resultados de *pricing*. Frente a ello, el presente estudio compara varias especificaciones de la familia GARCH y utiliza pronósticos de varianza asociados al horizonte relevante de valuación, en lugar de reemplazar la dinámica futura por un único parámetro de estado estacionario.

En su estudio, Tong (2023) busca mejorar la precisión del modelo Black-Scholes mediante una revisión explícita del supuesto de volatilidad constante. Para ello, utiliza simulaciones Monte Carlo para simular trayectorias bajo Black-Scholes usando volatilidad implícita constante y después calibra un GARCH(1,1) con datos históricos para generar una volatilidad iterativa paso a paso dentro del mismo marco de simulación. Los precios obtenidos se comparan con precios de mercado mediante RMSE, y el autor reporta una mejora moderada al incorporar GARCH. Sin embargo, también deja espacios abiertos, ya que compara sólo una especificación GARCH(1,1) y no analiza la sensibilidad del resultado a distintas familias GARCH o esquemas de estimación.

Finalmente, es importante reconocer que los errores de valuación no son homogéneos entre contratos. Christoffersen & Jacobs (2004) evalúan modelos GARCH considerando diferencias por *moneyness* y *maturity*, y reportan que el desempeño de un modelo puede variar según la posición de la opción con respecto al subyacente y el tiempo restante al vencimiento. Esto exige que la evaluación económica de los modelos GARCH aplicados a *pricing* deba considerar cómo los errores se distribuyen entre contratos con distintas características.

2.7. Evidencia empírica del DJIA y brecha identificada

La evidencia empírica sobre el pronóstico de volatilidad mediante modelos GARCH se ha concentrado principalmente en índices amplios y activos financieros de referencia. Hansen y Lunde (2005) comparan un amplio conjunto de especificaciones ARCH y encuentran que el GARCH(1,1) mantiene un desempeño sólido como modelo base, aunque ciertas especificaciones asimétricas pueden aportar mejoras en series de renta variable. Esta evidencia abre la necesidad de evaluar si dichos beneficios se mantienen en índices con una composición y metodología distintas, como el DJIA. Por su parte, Christoffersen y Jacobs (2004) vinculan los pronósticos de volatilidad GARCH con el *pricing* de opciones sobre el S&P 500, estableciendo una referencia metodológica para evaluar el valor económico de estos modelos. En conjunto, estos estudios

muestran que la evaluación de modelos GARCH ha sido ampliamente desarrollada en activos de referencia, pero no necesariamente en índices con estructuras distintas, como el DJIA.

Además, la literatura comparativa presenta limitaciones metodológicas relevantes. Aunque especificaciones como EGARCH, GJR-GARCH y APARCH permiten capturar efectos asimétricos y leverage, no existe consenso claro sobre cuál modelo domina de manera robusta. Asimismo, muchos estudios adoptan un único esquema de estimación, ya sea ventana fija o ventana móvil, sin contrastar ambos dentro del mismo marco empírico. Finalmente, la evaluación suele concentrarse en métricas estadísticas, aun cuando la métrica utilizada puede alterar el ranking entre modelos (Patton, 2011) y la evaluación estadística no necesariamente coincide con la evaluación económica (Christoffersen y Jacobs, 2004).

Ante estas limitaciones, este estudio desarrolla un marco comparativo aplicado al DJIA durante el periodo 2000–2025. El análisis evalúa cinco modelos GARCH bajo esquemas de ventana fija y rolling, e integra dentro de un mismo diseño empírico la evaluación estadística del pronóstico de volatilidad y su relevancia económica en el *pricing* de derivados.

3. Metodología

La metodología del estudio se construye para conectar la evidencia estadística de volatilidad condicional con una aplicación económica de valuación de opciones. La primera parte estima modelos de la familia ARCH sobre retornos diarios del DJIA y genera pronósticos de varianza acumulada a 21 días. La segunda parte transforma esos pronósticos en volatilidad anualizada y los utiliza como *input* del modelo Black-Scholes para calcular precios teóricos de opciones europeas. Esta estructura sigue la lógica de la revisión literaria, donde la volatilidad dinámica se justifica por hechos estilizados y la evaluación se separa entre precisión estadística y valor económico.

3.1. Datos y construcción de la serie de retornos

El activo subyacente utilizado para la estimación de los modelos de volatilidad es el Dow Jones Industrial Average, identificado en `yfinance` mediante el *ticker* `^DJI`. La base de datos se construye a partir de precios de cierre ajustados diarios descargados desde el 1 de enero de 2000 hasta el 31 de diciembre de 2025. Después de calcular retornos logarítmicos y eliminar la primera observación vacía, la muestra efectiva de retornos inicia el 4 de enero de 2000 y termina el 30 de diciembre de 2025, con un total de 6537 observaciones diarias.

Sea P_t el precio de cierre ajustado del índice en el día t . El retorno logarítmico diario se define como:

$$r_t = 100 \times \ln \frac{P_t}{P_{t-1}}$$

La multiplicación por 100 expresa los retornos en porcentaje, lo cual facilita la estimación numérica de los modelos ARCH y GARCH mediante la librería `arch`. Bajo esta convención, la varianza condicional estimada por los modelos se interpreta en unidades de porcentaje al cuadrado.

Para evaluar los pronósticos de volatilidad se construye un proxy de varianza realizada a 21 días hábiles. Este horizonte se selecciona porque aproxima un mes de negociación y coincide con el vencimiento utilizado posteriormente en la aplicación de opciones. Para cada fecha de pronóstico τ , la varianza realizada se calcula como la suma de retornos cuadrados durante el horizonte de evaluación.

$$RV_{\tau,21} = \sum_{j=1}^{21} r_{\tau+j}^2$$

El objeto que se pronostica no es la volatilidad diaria aislada, sino la varianza acumulada durante el horizonte relevante para la opción. Esto permite que la evaluación estadística de los modelos y la conversión posterior a volatilidad anualizada mantengan consistencia temporal.

3.2. Justificación estadística del uso de GARCH

La elección de modelos GARCH se fundamenta en la diferencia entre dependencia lineal en retornos y dependencia temporal en la varianza. La literatura revisada muestra que los retornos financieros pueden presentar baja predictibilidad en media y, al mismo tiempo, exhibir persistencia en la magnitud de sus movimientos. Esta regularidad corresponde al *volatility clustering* documentado por Mandelbrot et al. (1963) y Fama (1965), y formalizado posteriormente dentro de la literatura ARCH y GARCH por Engle (1982) y Bollerslev (1986).

La prueba ADF se utiliza para evaluar si la serie de retornos puede tratarse como estacionaria antes de estimar modelos de media y varianza condicional. La regresión auxiliar puede representarse como:

$$\Delta r_t = c + \eta r_{t-1} + \sum_{i=1}^q \psi_i \Delta r_{t-i} + u_t$$

La hipótesis nula corresponde a la presencia de una raíz unitaria, mientras que la alternativa implica estacionariedad. En el contexto de modelos GARCH, esta verificación es relevante porque la estimación de varianza condicional parte de una serie de retornos que debe oscilar alrededor de una media estable. La prueba no justifica por sí misma el uso de GARCH, pero establece que la dinámica modelada pertenece a fluctuaciones de corto plazo y no a una tendencia estocástica persistente en niveles.

La función de autocorrelación (ACF) se utiliza para medir la dependencia lineal de la serie en distintos rezagos. Para un rezago k , la autocorrelación muestral se define como:

$$\hat{\rho}_k(x) = \frac{\sum_{t=k+1}^n (x_t - \bar{x})(x_{t-k} - \bar{x})}{\sum_{t=1}^n (x_t - \bar{x})^2}$$

La función de autocorrelación parcial complementa este análisis al medir la relación entre r_t y r_{t-k} una vez controlados los rezagos intermedios. En la metodología del proyecto, ACF y PACF sobre retornos sirven para evaluar si es necesario incorporar una estructura de media, como un AR 1. ACF y PACF sobre retornos cuadrados sirven para evaluar si la magnitud de los retornos presenta persistencia temporal, lo cual constituye evidencia compatible con heterocedasticidad condicional.

La prueba Ljung-Box se utiliza para evaluar conjuntamente la autocorrelación hasta un número determinado de rezagos. Su estadístico se define como:

$$Q_m = n(n+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{n-k}$$

Cuando se aplica sobre r_t , la prueba permite evaluar dependencia serial en la media. Cuando se aplica sobre r_t^2 , permite evaluar dependencia serial en la varianza. Esta segunda aplicación es central para la justificación de modelos ARCH y GARCH, ya que la presencia de autocorrelación en retornos cuadrados implica que la varianza esperada en un periodo depende de información pasada. Esta lógica conecta directamente con Cont (2001), quien identifica la persistencia en retornos absolutos y cuadrados como uno de los hechos estilizados robustos de los mercados financieros.

Bajo este marco, las pruebas estadísticas no se utilizan como resultados finales sino como diagnóstico metodológico. Su función es justificar que la varianza no debe tratarse como constante y que modelos de volatilidad condicional son apropiados para capturar persistencia, reversión a la media y, en algunas especificaciones, asimetría ante choques negativos.

3.3. Especificación de los modelos de volatilidad

La estimación parte de una ecuación general de media y una ecuación de varianza condicional. Para los modelos GARCH, EGARCH, GJR-GARCH y APARCH se utiliza una media AR 1. Para el modelo ARCH se utiliza media constante que sirve como un modelo base para la comparativa. La estructura general de los modelos se escribe como:

$$r_t = \mu + \phi r_{t-1} + \epsilon_t$$

$$\epsilon_t = \sigma_t z_t$$

$$E[z_t] = 0, \quad Var[z_t] = 1$$

En el modelo ARCH, ϕ se fija en cero. En los demás modelos, ϕ se estima junto con los parámetros de volatilidad. Las innovaciones z_t siguen distintas distribuciones según la especificación computacional. ARCH, GARCH y GJR-GARCH se estiman con distribución Student-t. EGARCH se estima con distribución normal. APARCH se estima con distribución Skewed Student-t.

Los parámetros se estiman mediante máxima verosimilitud. Para un vector de parámetros θ , la estimación se define como:

$$\hat{\theta} = \arg \max_{\theta \in \Theta} \sum_{t=1}^T \ell_t(\theta)$$

$$\ell_t(\theta) = \log f_D(z_t; \psi) - \log \sigma_t$$

donde f_D representa la densidad de la distribución asumida para z_t y ψ agrupa parámetros de forma como grados de libertad y asimetría distribucional.

3.3.1. ARCH (1)

El modelo ARCH introducido por Engle (1982) permite que la varianza condicional dependa del choque cuadrático del periodo anterior. Su intuición es directa: si el mercado experimentó un movimiento grande ayer, positivo o negativo, el riesgo esperado para hoy aumenta. Esta especificación captura *volatility clustering* en su forma más simple y sirve como punto de partida para modelos más persistentes.

$$r_t = \mu + \epsilon_t$$

$$\epsilon_t = \sigma_t z_t$$

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2$$

Variable	Definición
r_t	retorno logarítmico diario en porcentaje
μ	media condicional constante
ϵ_t	innovación no esperada del retorno

Variable	Definición
σ_t^2	varianza condicional del retorno
z_t	innovación estandarizada con media cero y varianza unitaria
ω	componente constante de la varianza
α	sensibilidad de la varianza ante el choque cuadrático rezagado

El parámetro ω representa el nivel base de la varianza condicional, mientras que α_1 mide la reacción inmediata del riesgo ante nueva información. La principal limitación del ARCH (1) es su baja capacidad para capturar persistencia prolongada, ya que la varianza depende únicamente del último choque observado. Como señalan Bollerslev et al. (1992), una especificación ARCH puede requerir muchos rezagos para reproducir la persistencia empírica de la volatilidad financiera.

3.3.2. GARCH (1,1)

El modelo GARCH propuesto por Bollerslev (1986) extiende ARCH al incorporar rezagos de la propia varianza condicional. De esta forma, la volatilidad esperada depende tanto de nueva información como de la volatilidad previamente estimada. Esta combinación permite capturar persistencia con una especificación parsimoniosa, motivo por el cual P. R. Hansen & Lunde (2005) lo consideran un *benchmark* difícil de superar en evaluación estadística.

$$r_t = \mu + \phi r_{t-1} + \epsilon_t$$

$$\epsilon_t = \sigma_t z_t$$

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

Variable	Definición
r_t	retorno logarítmico diario en porcentaje
μ	constante de la ecuación de media
ϕ	coeficiente autorregresivo de la media
ϵ_t	innovación no esperada del retorno
σ_t^2	varianza condicional
z_t	innovación estandarizada
ω	nivel base de varianza
α	reacción de la varianza ante choques recientes
β	persistencia de la varianza condicional

El parámetro α captura la reacción de corto plazo ante nueva información, mientras que β captura la memoria del proceso de volatilidad. La suma $\alpha + \beta$ suele interpretarse como una medida de persistencia. La condición usual de estacionariedad en covarianza se expresa como

$$\alpha + \beta < 1$$

La limitación central del GARCH (1,1) es su simetría. La ecuación depende de ϵ_{t-1}^2 y no del signo de ϵ_{t-1} , por lo que choques positivos y negativos de igual magnitud tienen el mismo efecto sobre la volatilidad. Esta restricción entra en tensión con el *leverage effect* discutido por Christie (1982) y Engle & Patton (2001).

3.3.3. EGARCH (1,1)

El modelo EGARCH introducido por Nelson (1991) modela el logaritmo de la varianza condicional. Esta decisión elimina la necesidad de imponer restricciones de no negatividad sobre todos los parámetros, ya que la varianza resultante siempre es positiva al exponenciar el logaritmo.

$$r_t = \mu + \phi r_{t-1} + \epsilon_t$$

$$\epsilon_t = \sigma_t z_t$$

$$\log \sigma_t^2 = \omega + \alpha (|z_{t-1}| - E[|z_{t-1}|]) + \beta \log \sigma_{t-1}^2$$

Variable	Definición
r_t	retorno logarítmico diario en porcentaje
μ	constante de la ecuación de media
ϕ	coeficiente autorregresivo de la media
ϵ_t	innovación no esperada del retorno
σ_t^2	varianza condicional
z_t	innovación estandarizada
ω	nivel base del logaritmo de la varianza
α	reacción del logaritmo de la varianza ante la magnitud del choque
β	persistencia del logaritmo de la varianza

El componente $|z_{t-1}| - E[|z_{t-1}|]$ mide si la magnitud del choque fue mayor o menor a su valor esperado. La ventaja metodológica del EGARCH es que evita restricciones de positividad

y permite una dinámica multiplicativa de la varianza. Adicionalmente, su formulación en logaritmos favorece una estimación más estable y parsimoniosa, lo que facilita la comparabilidad empírica con otras especificaciones de la familia GARCH sin incurrir en sobreparametrización.

3.3.4. GJR-GARCH (1,1,1)

El modelo GJR-GARCH de Glosten et al. (1993) introduce una variable indicadora para distinguir choques negativos de choques positivos. Su objetivo es capturar que una caída del mercado puede elevar la volatilidad futura más que una subida de la misma magnitud. Esta estructura conecta directamente con la evidencia de asimetría documentada por Christie (1982) y con la discusión de Engle & Ng (1993) sobre funciones de impacto de noticias.

$$r_t = \mu + \phi r_{t-1} + \epsilon_t$$

$$\epsilon_t = \sigma_t z_t$$

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \gamma I_{t-1}^- \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

$$I_{t-1}^- = \mathbf{1}_{\{\epsilon_{t-1} < 0\}}$$

Variable	Definición
r_t	retorno logarítmico diario en porcentaje
μ	constante de la ecuación de media
ϕ	coeficiente autorregresivo de la media
ϵ_t	innovación no esperada del retorno
σ_t^2	varianza condicional
z_t	innovación estandarizada
ω	componente constante de la varianza
α	efecto de choques positivos y negativos en ausencia del término asimétrico
γ	efecto adicional asociado a choques negativos
I_{t-1}^-	indicador que toma valor uno cuando el choque rezagado es negativo
β	persistencia de la varianza condicional

Cuando ϵ_{t-1} es positivo, el efecto del choque sobre la varianza es $\alpha \epsilon_{t-1}^2$. Cuando ϵ_{t-1} es negativo, el efecto total es $(\alpha + \gamma) \epsilon_{t-1}^2$. La condición $\gamma > 0$ implica que las malas noticias aumentan la

volatilidad más que las buenas noticias de igual magnitud. La limitación del modelo es que la asimetría se introduce mediante un umbral discreto, por lo que la respuesta cambia únicamente al cruzar el signo cero.

3.3.5. APARCH (1,1,1)

El modelo APARCH propuesto por Ding et al. (1993) generaliza la familia ARCH al permitir que la potencia de la desviación estándar condicional sea estimada a partir de los datos. Además, incorpora asimetría mediante un parámetro que modifica el impacto de choques positivos y negativos. En este proyecto se estima con distribución Skewed Student-t, lo cual es consistente con la discusión de Fernández & Steel (1998) y B. E. Hansen (1994) sobre la necesidad de capturar colas pesadas y asimetría distribucional.

$$r_t = \mu + \phi r_{t-1} + \epsilon_t$$

$$\epsilon_t = \sigma_t z_t$$

$$\sigma_t^\delta = \omega + \alpha (|\epsilon_{t-1}| - \gamma \epsilon_{t-1})^\delta + \beta \sigma_{t-1}^\delta$$

Variable	Definición
r_t	retorno logarítmico diario en porcentaje
μ	constante de la ecuación de media
ϕ	coeficiente autorregresivo de la media
ϵ_t	innovación no esperada del retorno
σ_t	desviación estándar condicional
δ	potencia estimada de la desviación estándar condicional
z_t	innovación estandarizada
ω	componente constante
α	reacción ante choques rezagados ajustados por asimetría
γ	parámetro de asimetría en la respuesta a choques
β	persistencia de la volatilidad transformada
ν	grados de libertad de la distribución Skewed Student-t
λ	parámetro de sesgo de la distribución Skewed Student-t

El parámetro δ permite que la dinámica de la volatilidad sea determinada por los datos, en lugar de imponer una estructura fija sobre la varianza. Esto generaliza la familia GARCH al permitir distintas transformaciones de la desviación estándar condicional. Por su parte, γ introduce asimetría en la respuesta de la volatilidad, permitiendo que choques positivos y

negativos tengan impactos diferenciados. En conjunto, esta especificación amplía la capacidad del modelo para capturar regularidades empíricas observadas en series financieras bajo un marco unificado.

3.4. Esquemas de estimación

La comparación de modelos se realiza bajo dos esquemas de estimación. Esta decisión responde a la discusión de Stock & Watson (1996), Pesaran & Timmermann (2007), Inoue et al. (2017) y Marcucci et al. (2005) sobre inestabilidad paramétrica, selección de ventanas y posibles cambios de régimen. En particular, la muestra 2000-2025 incluye episodios de alta volatilidad como la crisis *dot-com*, la crisis financiera global, el COVID-19 y el ajuste posterior a la pandemia. Por ello, el estudio compara una estrategia que favorece estabilidad paramétrica con otra que privilegia adaptación a información reciente.

3.4.1. *Fixed Window*

En el esquema *Fixed Window*, los parámetros se estiman una sola vez utilizando información disponible hasta el 31 de diciembre de 2017. La muestra de entrenamiento inicia con el primer retorno efectivo, correspondiente al 4 de enero de 2000, y se mantiene fija para todo el periodo de evaluación. Los pronósticos fuera de muestra inician el 2 de enero de 2018 y se generan hasta el 1 de diciembre de 2025, fecha en la que todavía puede calcularse una varianza realizada futura de 21 días.

La estimación de parámetros se define como:

$$\hat{\theta}^{FW,m} = \arg \max_{\theta} \sum_{t \in \mathcal{T}_{train}} \ell_t(\theta)$$

Para cada fecha de pronóstico τ , el modelo genera una secuencia de varianzas condicionales futuras y se calcula la varianza acumulada pronosticada a 21 días.

$$\hat{\sigma}_{\tau,21}^{2,FW,m} = \sum_{j=1}^{21} \hat{\sigma}_{\tau+j|\tau}^{2,FW,m}$$

El superíndice m identifica el modelo de volatilidad. Bajo este esquema, los parámetros no se re-estiman durante el periodo de prueba. Sin embargo, la varianza condicional sí se actualiza mecánicamente con la información observada al avanzar el tiempo. Esta estrategia reduce la variabilidad de los parámetros estimados, pero puede ser menos sensible a cambios estructurales recientes.

3.4.2. *Rolling Window*

En el esquema *Rolling Window*, los modelos se estiman utilizando una ventana móvil de cinco años de negociación, equivalente a:

$$w = 252 \times 5 = 1260$$

Para cada fecha de pronóstico τ , la estimación utiliza únicamente las observaciones más recientes dentro de la ventana. La estimación se expresa como:

$$\hat{\theta}_{\tau}^{RW} = \arg \max_{\theta} \sum_{s=\tau-w}^{\tau-1} \ell_s(\theta)$$

El pronóstico de varianza acumulada se define como:

$$\hat{\sigma}_{\tau,21}^{2,RW,m} = \sum_{j=1}^{21} \hat{\sigma}_{\tau+j|\tau}^{2,RW,m}$$

La implementación re-estima los parámetros cada 21 días hábiles. Entre fechas de re-estimación, se conservan los últimos parámetros estimados y se actualiza el estado condicional del modelo con la ventana vigente. Esta decisión reduce el costo computacional y mantiene consistencia con un horizonte mensual de pronóstico. Para modelos con pronóstico analítico disponible se utiliza el método analítico, EGARCH y APARCH emplean simulación dado que el pronóstico analítico no está disponible.

El esquema *Rolling Window* permite que el modelo responda más rápido a cambios recientes de volatilidad, pero lo hace al costo de utilizar menos información histórica. Como mencionan Pesaran & Timmermann (2007), la comparación entre *Fixed Window* y *Rolling Window* puede interpretarse como un problema de sesgo y varianza, donde una ventana larga reduce ruido de estimación pero puede mezclar regímenes, mientras una ventana corta se adapta mejor pero puede producir parámetros más inestables.

3.5. Generación y evaluación de pronósticos de volatilidad

Para cada modelo y cada esquema de estimación se generan pronósticos diarios de varianza condicional acumulada a 21 días. Siguiendo a Brooks & Persaud (2003), la varianza a horizonte se construye agregando los pronósticos de varianza condicional de cada día futuro. Esta agregación es apropiada porque las varianzas son aditivas en el tiempo y porque el horizonte relevante para el problema no es el riesgo de un solo día, sino el riesgo acumulado hasta el vencimiento de la opción. En este estudio, dicho horizonte se fija en $h = 21$ días hábiles. Sea $s \in \{FW, RW\}$ el

esquema de estimación y sea m el modelo de volatilidad. El objeto pronosticado es la varianza acumulada a 21 días

$$\hat{\sigma}_{\tau,21}^{2,s,m} = \sum_{j=1}^{21} \hat{\sigma}_{\tau+j|\tau}^{2,s,m}$$

El *benchmark* observado para evaluación estadística es la varianza realizada construida con retornos cuadrados futuros.

$$RV_{\tau,21} = \sum_{j=1}^{21} r_{\tau+j}^2$$

Dado que la volatilidad no es observable directamente, la evaluación depende de un proxy. Por ello, se utiliza QLIKE como función de pérdida principal para los pronósticos de volatilidad. Siguiendo la justificación de Patton (2011), QLIKE es preferible cuando el proxy de volatilidad contiene error de medición, ya que preserva mejor el ranking de modelos bajo condiciones en las que métricas como RMSE pueden inducir comparaciones inconsistentes.

La función de pérdida QLIKE se define como:

$$QLIKE_{s,m} = \frac{1}{N} \sum_{\tau=1}^N \left[\frac{RV_{\tau,21}}{\hat{\sigma}_{\tau,21}^{2,s,m}} - \log \left(\frac{RV_{\tau,21}}{\hat{\sigma}_{\tau,21}^{2,s,m}} \right) - 1 \right]$$

QLIKE penaliza de forma asimétrica los errores de pronóstico. Un modelo que subestima fuertemente la volatilidad realizada recibe una penalización elevada, lo cual es relevante en contextos financieros donde subestimar riesgo puede ser más costoso que sobreestimarlos moderadamente. Además, su interpretación económica es adecuada para este proyecto porque el objetivo final no es sólo ajustar una serie estadística, sino generar *inputs* de volatilidad para valuación de opciones y comparación de errores de *pricing*.

3.6. Aplicación financiera mediante valuación de opciones

La aplicación financiera utiliza los pronósticos de volatilidad como insumo para el modelo Black-Scholes. En el modelo original de Black & Scholes (1973), el precio de una opción europea depende del precio del subyacente, el precio de ejercicio, el tiempo al vencimiento, la tasa libre de riesgo y la volatilidad anualizada del subyacente. La limitación central para este estudio es que la volatilidad se trata como constante durante la vida de la opción, mientras que la evidencia empírica y la literatura GARCH sugieren que la volatilidad cambia en el tiempo.

La estrategia del proyecto corresponde a un enfoque *plug-in*. En lugar de estimar un modelo formal de *pricing* GARCH bajo medida neutral al riesgo como Duan (1995), se estiman modelos

de volatilidad bajo la medida física con retornos históricos y sus pronósticos se introducen en Black-Scholes. Esta lógica es consistente con Bi et al. (2014) y Tong (2023), aunque el presente estudio amplía la comparación al incluir modelos simétricos, modelos con asimetría y dos esquemas de estimación.

3.6.1. Modelo Black-Scholes

Para una opción call europea, el precio teórico se calcula como:

$$C_t = S_t N(d_1) - K e^{-rT} N(d_2)$$

Para una opción put europea, el precio teórico se calcula como:

$$P_t = K e^{-rT} N(-d_2) - S_t N(-d_1)$$

Los términos d_1 y d_2 se definen como:

$$d_1 = \frac{\ln\left(\frac{S_t}{K}\right) + \left(r + \frac{1}{2}\sigma^2\right)T}{\sigma\sqrt{T}}$$

$$d_2 = d_1 - \sigma\sqrt{T}$$

Variable	Definición
C_t	precio teórico de una opción call europea
P_t	precio teórico de una opción put europea
S_t	precio del activo subyacente en la fecha de valuación
K	precio de ejercicio
T	tiempo al vencimiento expresado en años
r	tasa libre de riesgo anualizada en forma decimal
σ	volatilidad anualizada del subyacente en forma decimal
$N(\cdot)$	función de distribución acumulada normal estándar
d_1	distancia estandarizada ajustada por rendimiento libre de riesgo y volatilidad
d_2	distancia estandarizada ajustada por volatilidad durante el vencimiento

El modelo requiere que σ esté anualizada y expresada en forma decimal. Por ello, los pronósticos GARCH no pueden utilizarse directamente, ya que fueron generados como varianzas acumuladas a 21 días en unidades de porcentaje al cuadrado.

3.6.2. Conversión de pronósticos GARCH a volatilidad anualizada

Sea $\hat{\sigma}_{\tau,21}^{2,s,m}$ la varianza acumulada pronosticada por el modelo m bajo el esquema de estimación s para 21 días, expresada en porcentaje al cuadrado. La conversión a volatilidad anualizada en forma decimal se realiza mediante:

$$\hat{\sigma}_{\tau,ann}^{s,m} = \sqrt{\frac{\hat{\sigma}_{\tau,21}^{2,s,m}}{100^2} \cdot \frac{252}{21}}$$

El factor 100^2 convierte la varianza desde porcentaje al cuadrado hacia unidades decimales. El factor $\frac{252}{21}$ anualiza la varianza acumulada de 21 días bajo la convención de 252 días de negociación por año. La raíz cuadrada transforma varianza anualizada en volatilidad anualizada, que es el input requerido por Black-Scholes.

3.6.3. Benchmark de volatilidad histórica

Además de los pronósticos GARCH, se construye un benchmark clásico de volatilidad histórica anualizada con una ventana móvil de 252 días. Primero se convierten los retornos porcentuales a retornos decimales.

$$\tilde{r}_t = \frac{r_t}{100}$$

La media móvil de 252 días se define como:

$$\bar{r}_{t,252} = \frac{1}{252} \sum_{i=0}^{251} \tilde{r}_{t-i}$$

La volatilidad histórica anualizada se calcula como:

$$\sigma_{t,hist} = \sqrt{252} \sqrt{\frac{1}{251} \sum_{i=0}^{251} (\tilde{r}_{t-i} - \bar{r}_{t,252})^2}$$

Este *benchmark* representa el enfoque tradicional en el que la volatilidad se estima como una desviación estándar muestral sobre una ventana histórica fija. Su inclusión permite comparar si el uso de modelos GARCH aporta valor frente a una medida clásica que no modela explícitamente la persistencia, la reversión a la media ni la respuesta asimétrica ante choques.

3.6.4. Dataset de Opciones

La base de datos de opciones utilizada en este estudio proviene de OptionMetrics IvyDB US, una fuente especializada en información histórica de opciones listadas en Estados Unidos desde enero de 1996.

La muestra de opciones utilizada contiene contratos sobre el ticker DJX, que equivale al $\hat{DJI}$ dividido entre 100. Para cada contrato se dispone de la fecha de cotización, fecha de vencimiento, tipo de opción, precio de ejercicio, mejor cotización de compra (**best_bid**), mejor cotización de venta (**best_ask**), volatilidad implícita, entre otras. A partir de estas variables se calcula también el número de días al vencimiento como la diferencia entre la fecha de vencimiento y la fecha de cotización. El precio observado de cada opción se construye como el punto medio entre la mejor cotización de compra y la mejor cotización de venta:

$$O_i^{obs} = \frac{Bid_i + Ask_i}{2}$$

Para el análisis se selecciona el subconjunto de observaciones con 21 días al vencimiento. Esto permite que las observaciones estén alineados con el horizonte de pronóstico de volatilidad utilizado en el estudio.

El total de observaciones en la base de datos utilizada es de 10,152 observaciones, distribuidos entre 5,076 calls y 5,076 puts con vencimientos entre el 16 de febrero de 2018 y el 19 de septiembre de 2025.

La tasa libre de riesgo utilizada en Black-Scholes se aproxima mediante $\hat{IRX}$ descargado con *yfinance*, expresado en forma decimal. El tiempo al vencimiento se calcula como:

$$T_i = \frac{DTE_i}{365}$$

donde DTE_i representa los días calendario al vencimiento del contrato.

3.7. Métricas de error en *pricing*

La evaluación económica se realiza comparando precios observados de mercado contra precios teóricos generados con Black-Scholes. Para cada contrato i , esquema de estimación s y modelo de volatilidad m , el precio teórico se define como:

$$\widehat{O}_i^{s,m} = BS(S_i, K_i, T_i, r_i, \hat{\sigma}_{i,ann}^{s,m}, \text{type}_i)$$

El error de *pricing* se define como la diferencia entre el precio observado en el mercado y el precio teórico generado por el modelo.

$$e_i^{s,m} = O_i^{obs} - \widehat{O}_i^{s,m}$$

Un error positivo indica que el precio observado es mayor al precio teórico generado por el modelo. Un error negativo indica que el modelo produce un precio superior al observado en mercado. Esta convención permite evaluar directamente si los modelos tienden a subvaluar o sobrevaluar los contratos.

El RMSE mide el error cuadrático promedio y penaliza con mayor fuerza errores grandes.

$$RMSE_{s,m} = \sqrt{\frac{1}{N} \sum_{i=1}^N (e_i^{s,m})^2}$$

El MAE mide la magnitud absoluta promedio del error y es menos sensible a valores extremos que el RMSE.

$$MAE_{s,m} = \frac{1}{N} \sum_{i=1}^N |e_i^{s,m}|$$

A diferencia de QLIKE, estas métricas se aplican sobre precios observables y no sobre volatilidad latente. Por ello, su uso es consistente con Christoffersen & Jacobs (2004), quienes enfatizan que la evaluación de modelos de valuación debe estar alineada con la función de pérdida relevante para el objetivo económico. En este estudio, QLIKE evalúa la precisión estadística del pronóstico de volatilidad, mientras RMSE y MAE evalúan el desempeño económico en *pricing* de opciones.

Para complementar la evaluación agregada, los contratos pueden agruparse por *moneyness*. En la implementación computacional, la razón de *moneyness* se define de forma que valores cercanos a uno representen opciones *at-the-money* para *calls* y *puts*.

$$MNY_i = \begin{cases} \frac{S_i}{K_i}, & \text{type}_i = \text{call} \\ \frac{K_i}{S_i}, & \text{type}_i = \text{put} \end{cases}$$

Esta clasificación permite evaluar si los errores de *pricing* se concentran en contratos *at-the-money*, *near-the-money*, moderadamente *in-the-money* u *out-of-the-money*, y *deep in-the-money* u *out-of-the-money*. La motivación es que Christoffersen & Jacobs (2004) muestran que el desempeño de modelos de valuación puede variar sustancialmente según *moneyness* y vencimiento.

3.8. Implementación y reproducibilidad

La implementación se realiza en Python utilizando `pandas` y `numpy` para manipulación de datos, `yfinance` para descargar precios del DJIA y tasas de referencia, `statsmodels` para pruebas ADF, ACF, PACF y Ljung-Box, `arch` para estimar modelos ARCH y GARCH, y `scipy` para la función de distribución normal utilizada en Black-Scholes. La semilla de reproducibilidad se fija como `seed = 42`

Los parámetros operativos principales son:

Elemento	Valor utilizado
Horizonte de pronóstico	$h = 21$ días hábiles
Días de negociación por año	252
Fin de la muestra de entrenamiento Fixed Window	31 de diciembre de 2017
Inicio de evaluación fuera de muestra	2 de enero de 2018
Tamaño de Rolling Window	252×5 días
Frecuencia de re-estimación Rolling Window	cada 21 días hábiles

4. Resultados

4.1. Evidencia empírica inicial de la serie de retornos

La serie diaria de retornos logarítmicos del Dow Jones Industrial Average presenta rasgos consistentes con la necesidad de modelar la volatilidad de forma dinámica. El rendimiento promedio diario es positivo, aunque pequeño, con una media de 0.0222 % y una desviación estándar diaria de 1.1591 %.

La Figura 1 muestra la evolución temporal de los retornos diarios. Se observan episodios de alta volatilidad concentrados en ciertos periodos, lo que sugiere que la varianza no permanece constante en el tiempo.




Figura 1: Retornos Logarítmicos Diarios del DJIA

La asimetría negativa de -0.3478 indica que las caídas extremas tienden a ser más pronunciadas que los movimientos positivos equivalentes, mientras que la curtosis de Pearson de 15.9585 confirma una distribución altamente leptocúrtica. Esta evidencia es coherente con la presencia de colas pesadas, eventos extremos y desviaciones respecto al supuesto normal.

Tabla 1: Estadísticos descriptivos de los retornos diarios del DJIA

Estadístico	Valor
Media diaria (%)	0.0222
Desviación estándar diaria (%)	1.1591
Asimetría	-0.3478
Curtosis excedente	12.9585
Curtosis de Pearson	15.9585
Grados de libertad t-Student ajustada	2.7097

La evidencia descriptiva se refuerza visualmente en la Figura 2 al comparar la distribución empírica de los retornos con una distribución normal y una Student-t ajustada.




Figura 2: Distribución de los Retornos Diarios del DJIA frente a Distribuciones Normal y Student-t Ajustada

La distribución de los retornos muestra una concentración elevada alrededor de cero y colas más pesadas que la distribución normal. La distribución Student-t ajustada, con 2.71 grados de libertad, captura mejor esta característica que una distribución normal. Este resultado respalda el uso de innovaciones con distribución Student-t o sesgadas en varios de los modelos estimados.

Las pruebas de diagnóstico refuerzan la pertinencia del enfoque GARCH. La prueba ADF rechaza la hipótesis de raíz unitaria con un estadístico de -15.703 y un p-value cercano a cero, por lo que la serie de retornos puede tratarse como estacionaria. Sin embargo, la prueba Ljung-Box aplicada sobre los retornos muestra dependencia serial acumulada estadísticamente significativa para los rezagos 10 y 20. Al aplicar la misma prueba a la varianza realizada, los estadísticos aumentan considerablemente y los p-values son cero, lo que representa evidencia de dependencia temporal fuerte en los segundos momentos.

Tabla 2: Pruebas de estacionariedad y autocorrelación

Prueba	Estadístico	p-value	Interpretación
ADF sobre retornos	-15.7030	0.0000	Retornos estacionarios

Prueba	Estadístico	p-value	Interpretación
Ljung-Box retornos, lag 10	107.7131	1.54e-18	Autocorrelación estadísticamente significativa
Ljung-Box retornos, lag 20	179.0500	1.49e-27	Autocorrelación estadísticamente significativa
Ljung-Box varianza, lag 10	6232.1262	0.0000	Fuerte dependencia en volatilidad
Ljung-Box varianza, lag 20	8286.6317	0.0000	Fuerte dependencia en volatilidad

La evidencia de dependencia en la varianza también se observa directamente en la serie de varianza diaria realizada, como se muestra en la Figura 3.




Figura 3: Varianza Diaria Realizada del DJIA

En conjunto, los resultados muestran que el comportamiento de la volatilidad no es compatible con una varianza constante. La serie presenta colas pesadas, asimetría negativa y clustering de volatilidad, elementos que justifican el uso de modelos ARCH/GARCH y de extensiones asimétricas.

Para complementar la lectura visual anterior, la Figura 4 presenta las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de la varianza diaria.




Figura 4: ACF y PACF de la Varianza Diaria Realizada

La persistencia observada en la ACF de la varianza confirma que los segundos momentos de la serie contienen información predictiva. Este resultado es central para justificar modelos donde la varianza condicional depende de choques pasados y de su propia dinámica rezagada.

4.2. Resultados *in-sample* bajo esquema *Fixed Window*

La comparación *in-sample* se realizó mediante los criterios AIC y BIC. Ambos criterios penalizan la complejidad del modelo, aunque el BIC lo hace de forma más estricta. En este estudio, el modelo APARCH(1,1,1) con distribución Skewed Student-t es el que obtuvo el mejor ajuste, con el menor AIC y el menor BIC.

Tabla 3: Comparación in-sample: AIC y BIC

# Modelo	Modelo de media	Proceso de volatilidad	Distribución	AIC	BIC
1	Media constante	ARCH(1)	Student-t	12639.0054	12664.6766
2	AR(1)	GARCH(1,1)	Student-t	11737.1110	11775.6166
3	AR(1)	EGARCH(1,1)	Normal	11922.9646	11955.0525
4	AR(1)	GJR-GARCH(1,1)	Student-t	11584.4499	11629.3730
5	AR(1)	APARCH(1,1)	Skewed Student-t	11511.0937	11568.8520

El resultado favorece claramente a una especificación flexible y asimétrica. La ventaja de APARCH sobre GJR-GARCH es de aproximadamente 73.36 puntos en AIC y 60.52 puntos en BIC, lo que sugiere que la mejora de ajuste no proviene únicamente de agregar parámetros.

Además, el parámetro de asimetría estimado en APARCH y la distribución Skewed Student-t capturan la respuesta diferencial ante choques negativos y una distribución no simétrica de innovaciones.

Sin embargo, el ranking *in-sample* no debe interpretarse como evidencia definitiva de superioridad predictiva. La comparación con los resultados fuera de muestra muestra que el mejor ajuste estadístico dentro de la muestra no necesariamente coincide con el mejor desempeño predictivo o económico.

4.3. Pronóstico *out-of-sample* de Varianza

La evaluación fuera de muestra cubre el periodo del 2 de enero de 2018 al 1 de diciembre de 2025, con 1990 observaciones de pronóstico de varianza acumulada a 21 días, lo cual es consistente con la idea de que la volatilidad relevante para una opción debe reflejar el riesgo durante la vida del contrato. La métrica utilizada para evaluar el desempeño predictivo es QLIKE, donde valores más bajos indican mejor desempeño predictivo.

Tabla 4: QLIKE out-of-sample contra Varianza Realizada

Ranking	Modelo	QLIKE
1	EGARCH(1,1) Fixed-Window	0.4203
2	GARCH(1,1) Fixed-Window	0.4355
3	GARCH(1,1) Rolling-Window	0.4650
4	GJR-GARCH(1,1) Fixed-Window	0.4813
5	APARCH(1,1) Fixed-Window	0.4839
6	APARCH(1,1) Rolling-Window	0.5222
7	GJR-GARCH(1,1) Rolling-Window	0.5289
8	EGARCH(1,1) Rolling-Window	0.5298
9	ARCH(1) Fixed-Window	0.6201
10	ARCH(1) Rolling-Window	0.9479

El mejor desempeño frente a varianza realizada corresponde a EGARCH(1,1) con ventana fija. Esto es relevante porque EGARCH no fue el mejor modelo in-sample por AIC/BIC; aun así, genera la pérdida QLIKE más baja fuera de muestra. El segundo lugar corresponde a GARCH(1,1) con ventana fija, lo que confirma que una especificación parsimoniosa puede ser altamente competitiva en pronóstico agregado de volatilidad. ARCH(1), especialmente bajo rolling window, presenta el peor desempeño, lo que indica que incorporar únicamente choques rezagados sin persistencia suficiente en la varianza condicional es insuficiente para este horizonte.

La comparación entre esquemas de estimación también es informativa. Para el criterio QLIKE contra varianza realizada, las especificaciones con ventana fija dominan en varios casos a sus

versiones rolling. Esto sugiere que, en el pronóstico estadístico agregado de varianza a 21 días, estimar con una base histórica amplia puede aportar estabilidad y reducir la variabilidad de parámetros.

A modo ilustrativo, la Figura 5 muestra la evolución temporal de los pronósticos de varianza acumulada a 21 días para los modelos EGARCH(1,1) bajo ventana fija y GARCH(1,1) bajo ventana fija y rolling, comparados contra la varianza realizada.




Figura 5: Comparación de Pronósticos de Varianza contra Varianza Realizada

Otra forma de interpretar los errores en pronóstico de varianza es como la diferencia entre la varianza realizada y la varianza pronosticada. La Sección 7.1 muestra el conjunto de gráficas que ilustran estos errores para cada modelo y esquema de estimación. En general, los modelos con menor QLIKE presentan errores más concentrados alrededor de cero, mientras que ARCH, especialmente bajo rolling window, muestra errores más amplios y con mayor dispersión.

Los diagnósticos visuales modelo por modelo se reportan en la Sección 7.2. En conjunto, estos gráficos confirman que las especificaciones con menor QLIKE presentan menor dispersión relativa frente a la volatilidad realizada, mientras que ARCH, especialmente bajo rolling window, muestra errores más amplios y menor capacidad para capturar episodios de volatilidad elevada.

Como contraste adicional, se compararon los pronósticos de volatilidad anualizada contra la volatilidad implícita observada en el dataset de opciones.

Tabla 5: QLIKE out-of-sample contra Volatilidad Implícita

Ranking	Modelo	QLIKE
1	ARCH(1) Rolling-Window	0.4564
2	ARCH(1) Fixed-Window	0.4569
3	EGARCH(1,1) Rolling-Window	0.7736
4	GARCH(1,1) Rolling-Window	0.8090
5	EGARCH(1,1) Fixed-Window	0.8378
6	APARCH(1,1) Rolling-Window	0.8800
7	Volatilidad histórica 252 días	0.8912
8	GARCH(1,1) Fixed-Window	0.9037
9	GJR-GARCH(1,1) Rolling-Window	0.9192
10	APARCH(1,1) Fixed-Window	0.9885
11	GJR-GARCH(1,1) Fixed-Window	1.0312

Este ranking cambia de forma considerable respecto al obtenido con varianza realizada. ARCH aparece cerca de la volatilidad implícita, pero ese resultado no implica que sea superior para pricing. La volatilidad implícita incorpora primas de riesgo, expectativas de mercado y efectos cross-section por strike y tipo de opción, mientras que los modelos GARCH generan una volatilidad por fecha basada en la historia del subyacente. Por este motivo la volatilidad implícita suele ser mayor a la volatilidad realizada y el modelo ARCH, al no incorporar la persistencia tiende a sobreestimar la volatilidad. En el resultado podemos observar que este sesgo coincide accidentalmente con los niveles elevados del mercado. Por ello, la comparación contra volatilidad implícita debe interpretarse como un contraste de cercanía al mercado, no como una prueba directa de capacidad predictiva ni de precisión económica.

La diferencia entre los rankings confirma que el desempeño de un modelo depende del objeto de evaluación, ya sea varianza realizada, volatilidad implícita o precio de opción. Esto refuerza la idea de que un modelo puede minimizar errores de volatilidad y no necesariamente minimizar errores de pricing, y viceversa.

4.4. Aplicación Económica: Pricing de Opciones

La evaluación económica se realizó usando los pronósticos en precios de contratos tras evaluar el modelo Black-Scholes con la volatilidad anualizada derivada de los modelos GARCH como *input*.

La muestra final contiene 10,152 observaciones de opciones que se clasificaron por *moneyness* para evaluar si el desempeño de los modelos cambia según la posición relativa del strike y el subyacente. La clasificación utiliza la razón de *moneyness* definida como MNY de forma que valores cercanos a uno representen opciones *at-the-money* tanto para *calls* como para *puts*.

Tabla 6: Distribución de Contratos por Categoría de Moneyness

Categoría	Rango de moneyness	Observaciones
ATM	$0.97 \leq \text{MNY} \leq 1.03$	1,144
Near-the-money	$0.94 < \text{MNY} < 0.97$ o $1.03 < \text{MNY} < 1.06$	1,077
Moderately OTM/ITM	$0.88 < \text{MNY} \leq 0.94$ o $1.06 \leq \text{MNY} < 1.12$	1,693
Deep OTM/ITM	$\text{MNY} < 0.88$ o $\text{MNY} \geq 1.12$	6,238

El ranking por RMSE muestra que el modelo GJR-GARCH(1,1,1) con *Rolling Window* ocupa el primer lugar en las cuatro categorías de *moneyness*. Esto sugiere que, aunque no fue el mejor modelo en AIC/BIC ni en QLIKE contra varianza realizada, sí entrega el mejor desempeño económico al traducir la volatilidad pronosticada a precios teóricos de opciones.

Tabla 7: Top 3 Modelos por RMSE en cada categoría de moneyness

Categoría	Ranking	Modelo	RMSE	MAE
ATM	1	GJR-GARCH(1,1) Rolling-Window	1.0205	0.7428
ATM	2	APARCH(1,1) Fixed-Window	1.0375	0.7702
ATM	3	APARCH(1,1) Rolling-Window	1.0919	0.7952
Near-the-money	1	GJR-GARCH(1,1) Rolling-Window	0.8840	0.6166
Near-the-money	2	APARCH(1,1) Fixed-Window	0.9463	0.6555
Near-the-money	3	APARCH(1,1) Rolling-Window	0.9588	0.6521
Moderately OTM/ITM	1	GJR-GARCH(1,1) Rolling-Window	0.6557	0.4175
Moderately OTM/ITM	2	APARCH(1,1) Rolling-Window	0.6967	0.4306
Moderately OTM/ITM	3	APARCH(1,1) Fixed-Window	0.6972	0.4348
Deep OTM/ITM	1	GJR-GARCH(1,1) Rolling-Window	0.5804	0.3443
Deep OTM/ITM	2	APARCH(1,1) Rolling-Window	0.5834	0.3426
Deep OTM/ITM	3	EGARCH(1,1) Fixed-Window	0.5856	0.3442

La superioridad de GJR-GARCH rolling en *pricing* sugiere que el efecto asimétrico tipo leverage es especialmente útil cuando la volatilidad se utiliza para valorar opciones. El resultado también muestra que la actualización de parámetros mediante *rolling window* no necesariamente mejora

el pronóstico agregado de varianza, pero sí puede mejorar la capacidad del modelo para generar precios cercanos al mercado.

APARCH aparece de manera consistente entre los primeros lugares, especialmente en las categorías *ATM*, *near-the-money* y *moderately OTM/ITM*. Sin embargo, su ventaja *in-sample* no se traduce en el primer lugar económico. Este resultado evidencia que la mayor flexibilidad paramétrica mejora el ajuste histórico, pero no garantiza la menor pérdida de *pricing*.

En la categoría deep OTM/ITM las diferencias entre los mejores modelos son pequeñas. El RMSE del primer lugar es 0.5804, frente a 0.5834 para APARCH rolling y 0.5856 para EGARCH fixed. Esto indica que, en opciones más alejadas del dinero, el ranking es menos contundente y la distancia entre modelos se reduce.

Para evaluar el valor agregado frente a una alternativa clásica, se compara el MAE del mejor modelo económico (GJR-GARCH *Rolling*) contra el *benchmark* de volatilidad histórica anualizada con ventana de 252 días y contra el peor modelo global (ARCH *Rolling*).

Tabla 8: Comparación de MAE por Categoría

Categoría	GJR-GARCH Rolling	Volatilidad histórica 252 días	ARCH Rolling
ATM	0.7428	1.3859	3.0921
Near-the-money	0.6166	0.9499	2.1586
Moderately OTM/ITM	0.4175	0.5584	1.0536
Deep OTM/ITM	0.3443	0.3503	0.3916




Figura 6: Comparación de MAE entre GJR-GARCH Rolling, Volatilidad Histórica y ARCH Rolling

El modelo GJR-GARCH rolling reduce el MAE frente a la volatilidad histórica en todas las categorías. La mejora es mayor en contratos *ATM*, donde el MAE cae de 1.3859 a 0.7428, una reducción aproximada de 46.4 %. En *near-the-money* la reducción es de 35.1 %, y en *moderately OTM/ITM* es de 25.2 %. En *deep OTM/ITM* la mejora es mucho menor, cercana a 1.7 %, lo que indica que la volatilidad histórica simple ya es competitiva para contratos muy alejados del dinero.

Este patrón es financieramente razonable. Las opciones *ATM* y cercanas al dinero son más sensibles a cambios en volatilidad, por lo que una estimación dinámica de volatilidad tiene mayor capacidad de mejorar el precio teórico. En cambio, para opciones *deep OTM/ITM*, una parte importante del precio está determinada por el valor intrínseco o por probabilidades de ejercicio muy bajas, de modo que la ganancia marginal de sofisticar el modelo de volatilidad es más limitada.

Por último, la Figura 7 muestra que incorporar volatilidad condicional mediante modelos como el GJR-GARCH aporta mejoras sustanciales en la valuación de opciones frente al uso de volatilidad histórica constante. En todas las categorías analizadas, los errores de valuación disminuyen de manera consistente, alcanzando reducciones de hasta 46.40 % en MAE y 49.85 % en RMSE. Estos resultados confirman que la volatilidad en los mercados financieros no es estática, sino dinámica y dependiente de la información pasada, por lo que asumir una volatilidad histórica fija limita significativamente la precisión de los modelos tradicionales.




Figura 7: Reducción porcentual de errores del mejor modelo frente a volatilidad histórica por categoría de moneyness

5. Conclusión

Los resultados de este proyecto muestran que la elección del “mejor” modelo GARCH depende directamente del objetivo de evaluación. En términos de ajuste *in-sample*, APARCH(1,1) con distribución Skewed Student-t fue el modelo más sólido, ya que capturó con mayor flexibilidad la dinámica histórica de los retornos. En el pronóstico estadístico *out-of-sample*, EGARCH(1,1) con ventana fija obtuvo el mejor desempeño frente a la varianza realizada, lo que confirma que una especificación asimétrica y relativamente parsimoniosa puede ser altamente competitiva cuando el criterio central es minimizar la pérdida de volatilidad. Sin embargo, al trasladar los pronósticos de volatilidad a una aplicación financiera concreta, el resultado más relevante cambia; el modelo GJR-GARCH(1,1) con *rolling window* consiguió un mejor desempeño económico, al obtener el menor error de *pricing* en las cuatro categorías de *moneyness* evaluadas.

Este resultado es importante porque confirma que precisión estadística y valor económico no son equivalentes. Un modelo puede ajustarse mejor a los retornos históricos o pronosticar mejor la varianza realizada y, aun así, no ser el que genera precios de opciones más cercanos al mercado. La principal contribución del proyecto está precisamente en mostrar que evaluar modelos de volatilidad únicamente con criterios estadísticos puede ser insuficiente cuando el objetivo final es una aplicación financiera. En este caso, el criterio económico permitió identificar que el modelo más útil para *pricing* no fue el más complejo ni el de mejor ajuste *in-sample*, sino aquel que tradujo mejor la información de volatilidad hacia precios teóricos.

La superioridad de GJR-GARCH en *pricing* puede explicarse por su capacidad para capturar el efecto asimétrico tipo leverage. En mercados accionarios, los choques negativos suelen tener un impacto mayor sobre la volatilidad futura que los choques positivos de magnitud similar. Esta característica es especialmente relevante para opciones, porque su valor depende no solo del nivel esperado de volatilidad, sino también de cómo el *market* incorpora episodios de riesgo, caídas del subyacente y cambios en la distribución esperada de retornos. Al combinar esta respuesta asimétrica con una estimación rolling, GJR-GARCH logra adaptarse mejor a condiciones recientes de *market* sin depender de una flexibilidad paramétrica excesiva. Por eso APARCH puede dominar en ajuste histórico, pero GJR-GARCH resulta más consistente cuando el objetivo es reducir errores de valuación.

Desde la aplicación financiera, el hallazgo más claro es que incorporar volatilidad condicional dinámica mejora de forma consistente el *pricing* frente al *benchmark* clásico de volatilidad histórica de 252 días. La mejora fue especialmente fuerte en opciones *at-the-money* y *near-the-money*, donde la sensibilidad del precio a cambios en volatilidad es mayor. En cambio, para opciones deep *OTM/ITM*, la ganancia fue más limitada, lo cual es financieramente razonable ya que en estos contratos, una parte importante del precio está determinada por el valor intrínseco o por probabilidades de ejercicio muy bajas, de modo que sofisticar la estimación de volatilidad aporta menos valor marginal.

El alcance del proyecto no debe entenderse como una comparación restringida a Black-Scholes, sino como una prueba de la idea que cuando un modelo financiero depende de un *input* de volatilidad, sustituir una medida histórica no condicional por una estimación condicional dinámica puede mejorar la calidad de la decisión. En este trabajo dicha idea se evaluó mediante *pricing* de opciones, pero el mismo enfoque puede trasladarse a aplicaciones como VaR, *Expected Shortfall*, *stress testing*, cobertura, asignación de portafolios o simulación de escenarios.

Las limitaciones del estudio abren oportunidades claras para investigación futura. Primero, sería útil replicar la metodología en otros índices, acciones individuales o mercados internacionales para evaluar si la superioridad de GJR-GARCH en *pricing* se mantiene bajo distintas estructuras de liquidez, volatilidad y composición sectorial. Segundo, futuras extensiones podrían incorporar una comparación más detallada por vencimiento, tipo de opción y régimen de *market*, dado que la utilidad de cada modelo puede variar entre periodos de calma y episodios de estrés financiero. Tercero, sería relevante complementar la evaluación de *pricing* con métricas de cobertura, ya que un modelo que minimiza errores de precio no necesariamente minimiza errores de *hedge*. Finalmente, una extensión natural sería comparar este enfoque *plug-in* con modelos de valuación que incorporen la dinámica GARCH directamente bajo una medida de *pricing*.

En conjunto, los resultados apoyan el uso de modelos GARCH asimétricos para aplicaciones financieras de valuación de opciones. La evidencia muestra que modelar explícitamente la persistencia, la reversión y la respuesta asimétrica de la volatilidad aporta información económicamente útil frente a una volatilidad histórica simple. Bajo el diseño empírico de este proyecto, GJR-GARCH con *rolling window* ofrece el mejor balance entre adaptación a condiciones recientes, captura del efecto leverage y precisión en *pricing*.


6. Bibliografía




- Akaike, H. (1974). A new look at the statistical model identification. *IEEE transactions on automatic control*, 19(6), 716-723.
- Bi, Z., Yousuf, A., & Dash, M. (2014). A study on options pricing using GARCH and Black-Scholes-Merton model. *Asian Journal of Finance & Accounting*, 6(1), 423-439.
- Black, F., & Scholes, M. (1973). The pricing of options and corporate liabilities. *Journal of political economy*, 81(3), 637-654.
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of econometrics*, 31(3), 307-327.
- Bollerslev, T., Chou, R. Y., & Kroner, K. F. (1992). ARCH modeling in finance: A review of the theory and empirical evidence. *Journal of econometrics*, 52(1-2), 5-59.
- Brooks, C., & Persaud, G. (2003). Volatility Forecasting for Risk Management. *Journal of Forecasting*, 22(1), 1-22.
- Christie, A. A. (1982). The stochastic behavior of common stock variances: Value, leverage and interest rate effects. *Journal of financial Economics*, 10(4), 407-432.
- Christoffersen, P., Heston, S., & Jacobs, K. (2006). Option valuation with conditional skewness. *Journal of Econometrics*, 131(1-2), 253-284.
- Christoffersen, P., & Jacobs, K. (2004). The importance of the loss function in option valuation. *Journal of Financial Economics*, 72(2), 291-318.
- Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative finance*, 1(2), 223.
- Ding, Z., Granger, C. W., & Engle, R. F. (1993). A long memory property of stock market returns and a new model. *Journal of empirical finance*, 1(1), 83-106.
- Duan, J.-C. (1995). The GARCH option pricing model. *Mathematical finance*, 5(1), 13-32.
- Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica: Journal of the econometric society*, 987-1007.
- Engle, R. F., & Ng, V. K. (1993). Measuring and testing the impact of news on volatility. *The journal of finance*, 48(5), 1749-1778.
- Engle, R. F., & Patton, A. J. (2001). What good is a volatility model? En *Forecasting volatility in the financial markets* (pp. 47-63). Elsevier.
- Fama, E. F. (1965). The behavior of stock-market prices. *The journal of Business*, 38(1), 34-105.
- Fernández, C., & Steel, M. F. (1998). On Bayesian modeling of fat tails and skewness. *Journal of the american statistical association*, 93(441), 359-371.
- Glosten, L. R., Jagannathan, R., & Runkle, D. E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *The journal of finance*, 48(5), 1779-1801.
- Hansen, B. E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 705-730.
- Hansen, P. R., & Lunde, A. (2005). A forecast comparison of volatility models: does anything beat a GARCH (1, 1)? *Journal of applied econometrics*, 20(7), 873-889.




- Hull, J., & White, A. (1987). The pricing of options on assets with stochastic volatilities. *The journal of finance*, 42(2), 281-300.
- Inoue, A., Jin, L., & Rossi, B. (2017). Rolling window selection for out-of-sample forecasting with time-varying parameters. *Journal of econometrics*, 196(1), 55-67.
- Mandelbrot, B. et al. (1963). The variation of certain speculative prices. *Journal of business*, 36(4), 394.
- Marcucci, J. et al. (2005). Forecasting stock market volatility with regime-switching GARCH models. *Studies in Nonlinear Dynamics & Econometrics*, 9(4), 1-53.
- Nelson, D. B. (1991). Conditional heteroskedasticity in asset returns: A new approach. *Econometrica: Journal of the econometric society*, 347-370.
- Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of econometrics*, 160(1), 246-256.
- Pesaran, M. H., & Timmermann, A. (2007). Selection of estimation window in the presence of breaks. *Journal of Econometrics*, 137(1), 134-161.
- Poon, S.-H., & Granger, C. W. J. (2003). Forecasting volatility in financial markets: A review. *Journal of economic literature*, 41(2), 478-539.
- Schwarz, G. (1978). Estimating the dimension of a model. *The annals of statistics*, 461-464.
- Stock, J. H., & Watson, M. W. (1996). Evidence on structural instability in macroeconomic time series relations. *Journal of Business & Economic Statistics*, 14(1), 11-30.
- Tong, T. (2023). Enhancing Option Pricing Accuracy through Empirical Performance: A GARCH-Based Approach to Refining Volatility Assumptions in the Black-Scholes Model. *Highlights in Business, Economics and Management*, 22, 75-82.


7. Apéndices

7.1. Apéndice A: Errores en Pronósticos de Varianza Realizada











7.2. Apéndice B: Dispersión Relativa de Varianza Pronosticada frente Varianza Realizada


Varianza realizada vs. varianza pronosticada en escala log-log - ARCH(1) (Fixed-Window) (pendiente = 4..!




Varianza realizada vs. varianza pronosticada en escala log-log - ARCH(1) (Rolling-Window) (pendiente = 0.




Varianza realizada vs. varianza pronosticada en escala log-log - GARCH(1,1) (Fixed-Window) (pendiente = 1)




Varianza realizada vs. varianza pronosticada en escala log-log - GARCH(1,1) (Rolling-Window) (pendiente = 1)




Varianza realizada vs. varianza pronosticada en escala log-log - EGARCH(1,1) (Fixed-Window) (pendiente =




Varianza realizada vs. varianza pronosticada en escala log-log - EGARCH(1,1) (Rolling-Window) (pendiente =




Varianza realizada vs. varianza pronosticada en escala log-log - GJR-GARCH(1,1) (Fixed-Window) (pendiente :



Varianza realizada vs. varianza pronosticada en escala log-log - GJR-GARCH(1,1) (Rolling-Window) (pendiente :



Varianza realizada vs. varianza pronosticada en escala log-log - APARCH(1,1) (Fixed-Window) (pendiente =



Varianza realizada vs. varianza pronosticada en escala log-log - APARCH(1,1) (Rolling-Window) (pendiente =

